Universidad de los Andes · Maestría en Inteligencia Artificial
Aprendizaje por Refuerzo · Prof. Nicolás Cardozo

Agente de RL para la consolidación de órdenes de picking en un centro de distribución

Entrega 1: estados, acciones y función de recompensa

Miguel Ángel Muñoz Layton · [Nombre del compañero]

Noviembre de 2026

1. Descripción de la aplicación

Un agente de aprendizaje por refuerzo decide, cada vez que un operario queda libre, qué trabajo de picking liberar en un centro de distribución (CD): un lote consolidado de una zona de racks, una orden urgente individual, o esperar a que lleguen más órdenes. El objetivo es reducir los recorridos a los racks agrupando ítems repetidos entre órdenes, sin incumplir el deadline de ninguna orden.

El problema. A lo largo del turno llegan órdenes de compra. Cada orden tiene líneas (SKU y cantidad), cada SKU tiene una ubicación fija en un rack y cada orden tiene un deadline (hora de corte del transportista). Si cada orden se recoge por separado y 5 órdenes piden el mismo SKU, un operario va 5 veces a la misma ubicación. El agente agrupa esas líneas para hacer una sola visita y recoger las 5 unidades.

La tensión que aprende el agente. Esperar a que lleguen más órdenes aumenta la consolidación, pero consume holgura frente al deadline y deja operarios ociosos. Una regla fija no resuelve bien ese balance cuando la demanda, el WIP y la cantidad de operarios cambian durante el día; por eso se plantea como un problema de RL.

Supuestos del entorno.

- Los racks están organizados en 4 zonas, $Z = \{A, B, C, D\}$; cada zona es un grupo de pasillos contiguos.
- Un episodio es un turno de 8 horas.
- Cada operario lleva un carro con capacidad de $C_{\max} = 20$ líneas.
- El número de operarios puede variar en el turno (pausas, ausencias); el agente observa cuántos están libres.
- Las órdenes llegan de forma estocástica; el agente no conoce las órdenes futuras.

Lote consolidado. Al liberar un lote en la zona z, el sistema toma las líneas pendientes de z ordenadas por deadline más cercano, hasta 20 líneas, y las agrupa por ubicación: todas las unidades del mismo SKU se recogen en una sola visita. Después se separan por orden en una mesa de consolidación (*put-wall*) antes del despacho.

Momentos de decisión. Hay una decisión (a) cada vez que un operario queda libre y (b) cada $\Delta t = 2$ min mientras haya operarios libres sin trabajo. Cada acción asigna como máximo un operario; si quedan más operarios libres, se toma otra decisión de inmediato sin que avance el reloj.

1.1 Comportamiento deseado y no deseado del agente

#	Comportamiento	Tipo	Cómo lo controla la recompensa
D1	Recoger en una sola visita un SKU que piden varias órdenes	Deseado	LOTE_z paga más cuanto mayor es c_z $(+1, +5, +10)$
D2	Atender primero las órdenes con holgura crítica (≤ 15 min)	Deseado	Bono de urgencia $+8$; -20 por orden vencida
D3	Mantener ocupados a los operarios cuando hay trabajo	Deseado	ESPERAR con operarios libres cuesta -1 o -3
D4	Esperar brevemente para formar lotes más grandes si llegan muchas órdenes y hay holgura	Deseado	ESPERAR da $+2$ si $\lambda = 2$ y la consolidación aún es baja
D5	Mantener controlado el WIP de cada zona	Deseado	-2 por zona saturada ($w_z = 3$) cuando avanza el reloj
D6	Despachar todas las órdenes antes del fin de turno	Deseado	$+3$ por orden a tiempo; -30 por orden pendiente al cierre
N1	Ir varias veces a la misma ubicación por órdenes distintas	No deseado	URGENTE sin urgencia cuesta -4; un lote sin repetidos solo paga $+1$
N2	Retener órdenes esperando consolidar hasta que vencen	No deseado	-20 por orden vencida, mayor que el mejor lote $(+18)$
N3	Dejar operarios ociosos con órdenes críticas pendientes	No deseado	ESPERAR con una zona crítica cuesta -10
N4	Olvidar zonas con poca coincidencia de SKU (inanición)	No deseado	Su urgencia u_z sube y su lote llega a pagar $+9$
N5	Atender una zona cómoda mientras otra tiene una orden crítica	No deseado	-6 extra a LOTE_z si otra zona es crítica y z no
N6	Asignar trabajo sin operarios libres o a una zona sin líneas	No deseado	Acción enmascarada; si se ejecuta, -50

Cuadro 1: Comportamientos del agente y el componente de recompensa que los incentiva o castiga.

2. Conjunto de estados

El estado es un vector de 14 variables discretas: tres por zona (WIP, consolidación y urgencia), más los operarios libres y la tasa de llegada de órdenes.

$$s = (w_A, w_B, w_C, w_D,\ c_A, c_B, c_C, c_D,\ u_A, u_B, u_C, u_D,\ o,\ \lambda), \qquad z \in Z = \{A, B, C, D\}.$$

Para abreviar, en el resto del documento se escribe

$$s = (w_A, w_B, w_C, w_D \mid c_A, c_B, c_C, c_D \mid u_A, u_B, u_C, u_D \mid o, \lambda).$$

Restricción de consistencia. Una zona sin WIP no tiene consolidación ni urgencia:

$$w_z = 0 \iff c_z = 0 \ \wedge\ u_z = 0.$$

Por tanto, cada zona tiene $1 + 3 \cdot 3 \cdot 3 = 28$ combinaciones válidas de (w_z, c_z, u_z).

Estado terminal. s_{fin} representa el fin del turno (8 h). Ahí termina el episodio y no hay acciones.

Var.	Significado	Dominio	Discretización
w_z	WIP de la zona z: líneas pendientes aún no asignadas a un operario	$\{0,1,2,3\}$	0 = 0 líneas; 1 = 1–5; 2 = 6–15; 3 = 16 o más (zona saturada)
c_z	Potencial de consolidación: máximo número de órdenes pendientes que piden un mismo SKU en z	$\{0,1,2\}$	0 = ningún SKU repetido; 1 = 2–4 órdenes comparten un SKU; 2 = 5 o más
u_z	Urgencia: holgura mínima entre las órdenes con líneas pendientes en z (holgura = deadline − hora actual − tiempo estimado de recogida)	$\{0,1,2,3\}$	0 = zona sin líneas; 1 = más de 60 min; 2 = 15–60 min; 3 = 15 min o menos, incluye vencidas (crítica)
o	Operarios libres en el momento de la decisión	$\{0,1,2,3\}$	0, 1, 2; 3 = tres o más
λ	Órdenes llegadas en los últimos 15 min	$\{0,1,2\}$	0 = menos de 5; 1 = 5–15; 2 = más de 15

Cuadro 2: Variables del estado y sus dominios.

Tamaño del espacio.

$$|S| = 28^4 \cdot 4 \cdot 3 + 1 = 7\,375\,873 \text{ estados.}$$

Es finito pero grande para una tabla Q completa. Una primera versión tabular con 2 zonas tiene $28^2 \cdot 12 + 1 = 9\,409$ estados.

El estado abstrae la posición exacta de cada SKU y la identidad de cada orden; esa información la usa el simulador para armar los lotes y contar eventos, no el agente para decidir.

2.1 Clases de estados relevantes

Para definir las acciones y las recompensas basta distinguir las siguientes clases. Sea $Z^+(s) = \{z \in Z : w_z \geq 1\}$ el conjunto de zonas con trabajo y $u_{\max} = \max_z u_z$.

Clase	Condición	Interpretación
S_0	$s = s_{\text{fin}}$	Fin del turno
S_1	$o = 0$	Todos los operarios ocupados
S_2	$o \geq 1$ y $Z^+(s) = \emptyset$	Hay operarios libres pero no hay trabajo pendiente
S_3	$o \geq 1$, $Z^+(s) \neq \emptyset$, $u_{\max} = 3$	Hay al menos una orden crítica
S_4	$o \geq 1$, $Z^+(s) \neq \emptyset$, $u_{\max} \leq 2$	Hay trabajo sin urgencia crítica

Cuadro 3: Partición del espacio de estados usada en acciones y recompensas.

3. Conjunto de acciones

El agente tiene 6 acciones: un lote consolidado por cada zona, recoger una orden urgente completa, o esperar.

$$A = \{\mathsf{LOTE}_A, \mathsf{LOTE}_B, \mathsf{LOTE}_C, \mathsf{LOTE}_D, \mathsf{URGENTE}, \mathsf{ESPERAR}\}.$$

Acción	Qué hace	Aplicable si
LOTE_z, $z \in Z$	Asigna un operario libre a un lote de la zona z: hasta 20 líneas por deadline más cercano, agrupadas por ubicación (una visita por SKU)	$o \geq 1$ y $w_z \geq 1$
URGENTE	Asigna un operario libre a recoger completa la orden con menor holgura de todo el CD, en todas sus zonas, sin mezclarla con otras órdenes	$o \geq 1$ y $Z^+(s) \neq \emptyset$
ESPERAR	No asigna trabajo; el reloj avanza hasta el siguiente evento (máximo $\Delta t = 2$ min) y pueden llegar órdenes nuevas	Siempre, salvo en s_{fin}

Cuadro 4: Acciones del agente.

Acciones aplicables por estado. Formalmente,

$$A(s) = \begin{cases} \emptyset & s \in S_0 \\ \{\mathsf{ESPERAR}\} & s \in S_1 \cup S_2 \\ \{\mathsf{LOTE}_z : z \in Z^+(s)\} \cup \{\mathsf{URGENTE},\ \mathsf{ESPERAR}\} & s \in S_3 \cup S_4 \end{cases}$$

Así, en $S_3 \cup S_4$ el agente tiene entre 3 y 6 acciones disponibles (según cuántas zonas tengan WIP). Las acciones fuera de $A(s)$ se enmascaran; si una implementación no las enmascara, ejecutar una acción inválida da -50 y el estado no cambia ($s' = s$).

3.1 Dinámica de transición: cómo se llega a s'

La recompensa se define sobre la tripla (s, a, s'), así que conviene precisar qué cambia de s a s' con cada acción. Sea $\tau(s, a, s') \in \{0, 1\}$ un indicador de que el reloj avanzó entre s y s'.

Acción	Efecto inmediato	Avance del reloj
LOTE_z	$o \to o - 1$; salen de z hasta 20 líneas, y w_z, c_z, u_z se recalculan con las líneas que quedan	$\tau = 0$ si $o - 1 \geq 1$ y aún hay WIP (nueva decisión inmediata); si no, $\tau = 1$ y el reloj avanza hasta que un operario quede libre
URGENTE	$o \to o - 1$; salen las líneas de la orden más urgente en todas las zonas donde tenga líneas, y esas zonas se recalculan	Igual que LOTE_z
ESPERAR	Ninguno	$\tau = 1$: el reloj avanza Δt o hasta que se libere un operario, lo que ocurra primero

Cuadro 5: Transiciones por acción.

Cuando $\tau = 1$ ocurren los eventos estocásticos del ambiente: llegan órdenes (w, c y λ pueden subir), la holgura de las órdenes pendientes disminuye (u puede subir), operarios terminan su lote (o puede subir) y órdenes se completan o vencen. Si en el avance se alcanzan las 8 h, $s' = s_{\text{fin}}$.

4. Función de recompensa $R(s, a, s')$

La recompensa de cada tripla suma una parte inmediata, que depende del estado de salida y de la acción, y una parte de transición, que depende de lo que ocurrió entre s y s':

$$R(s, a, s') = R_{\text{acc}}(s, a) + R_{\text{tr}}(s, a, s').$$

4.1 Recompensa inmediata de LOTE_z

Es la suma de un pago por consolidación, $P_c(c_z)$, y un bono por urgencia, $B_u(u_z)$, de la zona elegida, menos una penalización por descuido si otra zona es crítica:

$$R_{\text{acc}}(s, \mathsf{LOTE}_z) = P_c(c_z) + B_u(u_z) - 6 \cdot \mathbf{1}\left[\exists z' \neq z : u_{z'} = 3 \ \wedge \ u_z < 3\right],$$

con $P_c(0) = 1$, $P_c(1) = 5$, $P_c(2) = 10$ y $B_u(1) = 0$, $B_u(2) = 3$, $B_u(3) = 8$.

	$u_z = 1$ (holgura > 60 min)	$u_z = 2$ (15–60 min)	$u_z = 3$ (crítica)
$c_z = 0$ (sin SKU repetido)	$+1$	$+4$	$+9$
$c_z = 1$ (2–4 órdenes comparten SKU)	$+5$	$+8$	$+13$
$c_z = 2$ (5 o más comparten SKU)	$+10$	$+13$	$+18$

Cuadro 6: $P_c(c_z) + B_u(u_z)$ para LOTE_z (antes de la penalización por descuido de -6).

4.2 Recompensa inmediata de URGENTE y ESPERAR

Las reglas de ESPERAR se evalúan en orden; aplica la primera que se cumpla.

Acción	**Condición sobre** s	$R_{\text{acc}}(s, a)$
URGENTE	$u_{\max} = 3$ (hay una orden crítica)	$+8$
	$u_{\max} = 2$	$+1$
	$u_{\max} = 1$ (no hay urgencia: desperdicia consolidación)	-4
ESPERAR	$s \in S_1$: $o = 0$ (no hay alternativa)	0
	$s \in S_2$: no hay trabajo pendiente	0
	$s \in S_3$: operario ocioso con una orden crítica	-10
	$s \in S_4$, $\lambda = 2$ y $c_z \leq 1 \ \forall z$ (vale la pena esperar para consolidar)	$+2$
	$s \in S_4$ y $\lambda = 0$ (no llegarán órdenes, esperar no sirve)	-3
	$s \in S_4$ en cualquier otro caso (operario ocioso)	-1

Cuadro 7: Recompensa inmediata de URGENTE y ESPERAR.

4.3 Recompensa de transición

Sean n_{ok} y n_{venc} el número de órdenes completadas a tiempo y de órdenes que vencieron sin completarse durante la transición $s \to s'$, y n_{pend} el número de órdenes pendientes al llegar a s_{fin}. Como el estado agregado no guarda la identidad de cada orden, el simulador registra estos conteos en cada transición; para una tripla concreta su valor es conocido.

$$R_{\text{tr}}(s, a, s') = 3\, n_{\text{ok}} - 20\, n_{\text{venc}} - 2\, \tau(s, a, s') \sum_{z \in Z} \mathbf{1}[w'_z = 3] - 30\, n_{\text{pend}}\, \mathbf{1}[s' = s_{\text{fin}}].$$

Justificación de los valores. Vencer una orden (-20) cuesta más que el mejor lote posible ($+18$), así que el agente nunca debería sacrificar un deadline por consolidar. Esperar ($+2$) paga menos que un lote con consolidación media ($+5$): el agente solo aprende a esperar cuando el valor futuro de un lote más grande ($+10$) lo compensa, que es justamente el balance que debe descubrir. Se recomienda un factor de descuento $\gamma = 0{,}99$ por decisión.

Evento en la transición (s, a, s')	**Recompensa**
Cada orden completada antes de su deadline	$+3$
Cada orden que vence sin completarse (se cuenta una sola vez por orden)	-20
Cada zona con $w'_z = 3$ en s', solo si el reloj avanzó ($\tau = 1$)	-2
Llegada a $s' = s_{\text{fin}}$: cada orden pendiente sin despachar	-30
Acción inválida ($a \notin A(s)$, si no hay enmascaramiento); en este caso $s' = s$ y no aplica nada más	-50

Cuadro 8: Recompensas de transición.

4.4 Triplas (s, a, s') de ejemplo

La tabla aplica la función completa a transiciones concretas que cubren todas las clases de estado y todas las acciones. Notación: $s = (w_A, w_B, w_C, w_D \mid c_A, c_B, c_C, c_D \mid u_A, u_B, u_C, u_D \mid o, \lambda)$.

#	**Estado de salida s y de llegada s'**	**Acción a**	**Cálculo**	$R(s, a, s')$
T1	$s = (1,2,0,0 \mid 0,2,0,0 \mid 3,1,0,0 \mid 2,1)$ $s' = (0,2,0,0 \mid 0,2,0,0 \mid 0,1,0,0 \mid 1,1)$	LOTE$_A$	$c_A = 0, u_A = 3$: $1+8$; queda un operario libre, $\tau = 0$	$+9$
T2	$s = (0,2,0,0 \mid 0,2,0,0 \mid 0,1,0,0 \mid 1,1)$ $s' = (0,0,1,0 \mid 0,0,0,0 \mid 0,0,1,0 \mid 1,1)$	LOTE$_B$	$c_B = 2$: $+10$ (5 órdenes con el mismo SKU en una visita); en el avance se completa la orden de A ($+3$) y llegan órdenes a C	$+13$
T3	$s = (2,1,0,0 \mid 1,0,0,0 \mid 1,1,0,0 \mid 1,1)$ $s' = (2,0,0,0 \mid 1,0,0,0 \mid 1,0,0,0 \mid 0,1)$	URGENTE	$u_{\max} = 1$: -4; sin eventos	-4
T4	$s = (0,0,1,0 \mid 0,0,0,0 \mid 0,0,3,0 \mid 1,1)$ $s' = (0,0,1,0 \mid 0,0,0,0 \mid 0,0,3,0 \mid 1,1)$	ESPERAR	$s \in S_3$: -10; la orden crítica vence: -20	-30
T5	$s = (2,1,0,0 \mid 1,1,0,0 \mid 1,1,0,0 \mid 1,2)$ $s' = (2,1,0,0 \mid 2,1,0,0 \mid 1,1,0,0 \mid 1,2)$	ESPERAR	$s \in S_4$, $\lambda = 2$, $c_z \leq 1$: $+2$; llegan órdenes y c_A sube a 2	$+2$
T6	$s = (3,1,0,0 \mid 1,0,0,0 \mid 2,1,0,0 \mid 0,1)$ $s' = (3,1,0,0 \mid 1,0,0,0 \mid 2,1,0,0 \mid 1,1)$	ESPERAR	$s \in S_1$: 0; se completa una orden: $+3$; A sigue saturada: -2	$+1$
T7	$s = (0,2,1,0 \mid 0,2,0,0 \mid 0,1,3,0 \mid 1,1)$ $s' = (0,0,1,0 \mid 0,0,0,0 \mid 0,0,3,0 \mid 0,1)$	LOTE$_B$	$+10$; descuido (C es crítica): -6; vence la orden de C: -20	-16
T8	$s = (1,0,0,0 \mid 0,0,0,0 \mid 3,0,0,0 \mid 0,0)$ $s' = s_{\text{fin}}$	ESPERAR	$s \in S_1$: 0; termina el turno con 2 órdenes pendientes: $2 \times (-30)$	-60
T9	$s = (1,2,0,0 \mid 0,2,0,0 \mid 3,1,0,0 \mid 2,1)$ $s' = s$ (sin cambio)	LOTE$_C$	$w_C = 0$: acción inválida	-50

Cuadro 9: Ejemplos de recompensa para triplas (s, a, s').

Las triplas T1 y T2 muestran el caso que motiva la aplicación: con una orden crítica en A y 5 órdenes que piden el mismo SKU en B, el agente atiende primero la urgencia ($+9$, frente a $+4$ de ir a B con la penalización por descuido) y luego recoge el SKU repetido en una sola visita ($+10$), en vez de ir 5 veces a la misma ubicación. T7 muestra el costo de ignorar una urgencia por perseguir consolidación.