Universidad de los Andes · Maestría en Inteligencia Artificial
Aprendizaje por Refuerzo · Prof. Nicolás Cardozo

Agente de RL para la consolidación de órdenes de picking en un centro de distribución

Entrega 1: estados, acciones y función de recompensa

Miguel Ángel Muñoz Layton · Daniel F. Barrera Armendaris

Noviembre de 2026

1. Descripción de la aplicación

Un agente de aprendizaje por refuerzo decide, cada vez que un operario queda libre, qué trabajo de picking liberar en un centro de distribución (CD): un lote consolidado de una zona de racks, una orden urgente individual, o esperar a que lleguen más órdenes. El objetivo es reducir los recorridos a los racks agrupando ítems repetidos entre órdenes, sin incumplir el deadline de ninguna orden.

El problema. A lo largo del turno llegan órdenes de compra. Cada orden tiene líneas (SKU y cantidad), cada SKU tiene una ubicación fija en un rack y cada orden tiene un deadline (hora de corte del transportista). Si cada orden se recoge por separado y 5 órdenes piden el mismo SKU, un operario va 5 veces a la misma ubicación. El agente agrupa esas líneas para hacer una sola visita y recoger las 5 unidades.

La tensión que aprende el agente. Esperar a que lleguen más órdenes aumenta la consolidación, pero consume holgura frente al deadline y deja operarios ociosos. Una regla fija no resuelve bien ese balance cuando la demanda, el WIP y la cantidad de operarios cambian durante el día; por eso se plantea como un problema de RL.

Supuestos del entorno.

- Los racks están organizados en 4 zonas, $Z = \{A, B, C, D\}$; cada zona es un grupo de pasillos contiguos.
- Un episodio es un turno de 8 horas.
- Cada operario lleva un carro con capacidad de $C_{\max} = 20$ líneas.
- El número de operarios puede variar en el turno (pausas, ausencias); el agente observa cuántos están libres.
- Las órdenes llegan de forma estocástica, con picos de demanda durante el turno; el agente no conoce las órdenes futuras.
- Pocos SKU concentran la mayor parte de la demanda (curva ABC), por lo que varias órdenes suelen pedir los mismos SKU.

Lote consolidado. Al liberar un lote en la zona z, el sistema toma las líneas pendientes de z ordenadas por deadline más cercano, hasta 20 líneas, y las agrupa por ubicación: todas las unidades del mismo SKU se recogen en una sola visita. Después se separan por orden en una mesa de consolidación (*put-wall*) antes del despacho.

Momentos de decisión. Hay una decisión (a) cada vez que un operario queda libre y (b) cada $\Delta t = 2$ min en cualquier caso: el reloj nunca avanza más de Δt por decisión. Si todos los operarios están ocupados, la única acción posible es esperar. Cada acción asigna como máximo un operario; si quedan más operarios libres y hay trabajo, se toma otra decisión de inmediato sin que avance el reloj.

1.1 Comportamiento deseado y no deseado del agente

#	Comportamiento	Tipo	Cómo lo controla la recompensa
D1	Recoger en una sola visita un SKU que piden varias órdenes	Deseado	+2 por cada visita ahorrada (líneas del lote menos ubicaciones visitadas)
D2	Atender primero las órdenes con holgura crítica (≤ 15 min)	Deseado	-1 por zona crítica cada vez que avanza el reloj; -20 por orden vencida
D3	Mantener ocupados a los operarios cuando hay trabajo	Deseado	ESPERAR con operarios libres cuesta -1 o -3, más el costo de WIP
D4	Esperar brevemente para formar lotes más grandes si llegan muchas órdenes y hay holgura	Deseado	ESPERAR no se penaliza (0) si $\lambda = 2$ y la consolidación aún es baja; las visitas ahorradas del lote siguiente pagan la espera
D5	Mantener controlado el WIP	Deseado	$-0{,}05$ por cada línea pendiente sin asignar, por minuto
D6	Despachar todas las órdenes antes del fin de turno	Deseado	+3 por orden a tiempo; -30 por orden pendiente al cierre
N1	Ir varias veces a la misma ubicación por órdenes distintas	No deseado	URGENTE sin urgencia cuesta -4 extra; cada viaje cuesta -1 y uno sin SKU repetidos no ahorra visitas
N2	Retener órdenes esperando consolidar hasta que vencen	No deseado	-20 por orden vencida, más que lo que ahorra consolidar todas sus líneas ($\leq +12$)
N3	Dejar operarios ociosos con órdenes críticas pendientes	No deseado	ESPERAR con una zona crítica cuesta -10
N4	Olvidar zonas con poca coincidencia de SKU (inanición)	No deseado	Su urgencia u_z sube: -1 por avance mientras sea crítica y -10 a los lotes de otras zonas
N5	Atender una zona cómoda mientras otra tiene una orden crítica	No deseado	-10 extra a LOTE_z si otra zona es crítica y z no
N6	Asignar trabajo sin operarios libres o a una zona sin líneas	No deseado	Acción enmascarada; si se ejecuta, -50

Cuadro 1: Comportamientos del agente y el componente de recompensa que los incentiva o castiga.

2. Conjunto de estados

El estado es un vector de 14 variables discretas: tres por zona (WIP, consolidación y urgencia), más los operarios libres y la tasa de llegada de órdenes.

$$s = (w_A, w_B, w_C, w_D,\ c_A, c_B, c_C, c_D,\ u_A, u_B, u_C, u_D,\ o,\ \lambda), \qquad z \in Z = \{A, B, C, D\}.$$

Para abreviar, en el resto del documento se escribe

$$s = (w_A, w_B, w_C, w_D \mid c_A, c_B, c_C, c_D \mid u_A, u_B, u_C, u_D \mid o, \lambda).$$

Var.	Significado	Dominio	Discretización
w_z	WIP de la zona z: líneas pendientes aún no asignadas a un operario	$\{0,1,2,3\}$	0 = 0 líneas; 1 = 1–5; 2 = 6–15; 3 = 16 o más (zona saturada)
c_z	Potencial de consolidación: máximo número de órdenes pendientes que piden un mismo SKU en z	$\{0,1,2\}$	0 = ningún SKU repetido; 1 = 2–4 órdenes comparten un SKU; 2 = 5 o más
u_z	Urgencia: holgura mínima entre las órdenes con líneas pendientes en z (holgura = deadline − hora actual − tiempo estimado de recogida)	$\{0,1,2,3\}$	0 = zona sin líneas; 1 = más de 60 min; 2 = 15–60 min; 3 = 15 min o menos, incluye vencidas (crítica)
o	Operarios libres en el momento de la decisión	$\{0,1,2,3\}$	0, 1, 2; 3 = tres o más
λ	Órdenes llegadas en los últimos 15 min	$\{0,1,2\}$	0 = menos de 5; 1 = 5–15; 2 = más de 15

Cuadro 2: Variables del estado y sus dominios.

Restricción de consistencia. Una zona sin WIP no tiene consolidación ni urgencia:

$$w_z = 0 \iff c_z = 0 \ \wedge \ u_z = 0.$$

Por tanto, cada zona tiene $1 + 3 \cdot 3 \cdot 3 = 28$ combinaciones válidas de (w_z, c_z, u_z).

Estado terminal. s_{fin} representa el fin del turno (8 h). Ahí termina el episodio y no hay acciones.

Tamaño del espacio.

$$|S| = 28^4 \cdot 4 \cdot 3 + 1 = 7\,375\,873 \text{ estados.}$$

Es finito pero grande para una tabla Q completa. Una primera versión tabular con 2 zonas tiene $28^2 \cdot 12 + 1 = 9\,409$ estados.

El estado abstrae la posición exacta de cada SKU y la identidad de cada orden; esa información la usa el simulador para armar los lotes y contar eventos, no el agente para decidir.

2.1 Clases de estados relevantes

Para definir las acciones y las recompensas basta distinguir las siguientes clases. Sea $Z^+(s) = \{z \in Z : w_z \geq 1\}$ el conjunto de zonas con trabajo y $u_{\max} = \max_z u_z$.

Clase	Condición	Interpretación
S_0	$s = s_{\text{fin}}$	Fin del turno
S_1	$o = 0$	Todos los operarios ocupados
S_2	$o \geq 1$ y $Z^+(s) = \emptyset$	Hay operarios libres pero no hay trabajo pendiente
S_3	$o \geq 1$, $Z^+(s) \neq \emptyset$, $u_{\max} = 3$	Hay al menos una orden crítica
S_4	$o \geq 1$, $Z^+(s) \neq \emptyset$, $u_{\max} \leq 2$	Hay trabajo sin urgencia crítica

Cuadro 3: Partición del espacio de estados usada en acciones y recompensas.

3. Conjunto de acciones

El agente tiene 6 acciones: un lote consolidado por cada zona, recoger una orden urgente completa, o esperar.

$$A = \{\mathsf{LOTE}_A, \mathsf{LOTE}_B, \mathsf{LOTE}_C, \mathsf{LOTE}_D, \mathsf{URGENTE}, \mathsf{ESPERAR}\}.$$

Acción	Qué hace	Aplicable si
LOTE_z, $z \in Z$	Asigna un operario libre a un lote de la zona z: hasta 20 líneas por deadline más cercano, agrupadas por ubicación (una visita por SKU)	$o \geq 1$ y $w_z \geq 1$
URGENTE	Asigna un operario libre a recoger completa la orden con menor holgura de todo el CD, en todas sus zonas, sin mezclarla con otras órdenes	$o \geq 1$ y $Z^+(s) \neq \emptyset$
ESPERAR	No asigna trabajo; el reloj avanza hasta el siguiente evento (máximo $\Delta t = 2$ min) y pueden llegar órdenes nuevas	Siempre, salvo en s_{fin}

Cuadro 4: Acciones del agente.

Acciones aplicables por estado. Formalmente,

$$A(s) = \begin{cases} \emptyset & s \in S_0 \\ \{\mathsf{ESPERAR}\} & s \in S_1 \cup S_2 \\ \{\mathsf{LOTE}_z : z \in Z^+(s)\} \cup \{\mathsf{URGENTE},\ \mathsf{ESPERAR}\} & s \in S_3 \cup S_4 \end{cases}$$

Así, en $S_3 \cup S_4$ el agente tiene entre 3 y 6 acciones disponibles (según cuántas zonas tengan WIP). Las acciones fuera de $A(s)$ se enmascaran; si una implementación no las enmascara, ejecutar una acción inválida da -50 y el estado no cambia ($s' = s$).

3.1 Dinámica de transición: cómo se llega a s'

La recompensa se define sobre la tripla (s, a, s'), así que conviene precisar qué cambia de s a s' con cada acción. Sea $\tau(s, a, s') \in \{0, 1\}$ un indicador de que el reloj avanzó entre s y s'.

Acción	Efecto inmediato	Avance del reloj
LOTE_z	$o \to o - 1$; salen de z hasta 20 líneas, y w_z, c_z, u_z se recalculan con las líneas que quedan	$\tau = 0$ si $o - 1 \geq 1$ y aún hay WIP (nueva decisión inmediata); si no, $\tau = 1$ y el reloj avanza Δt o hasta que un operario quede libre, lo que ocurra primero
URGENTE	$o \to o - 1$; salen las líneas de la orden más urgente en todas las zonas donde tenga líneas, y esas zonas se recalculan	Igual que LOTE_z
ESPERAR	Ninguno	$\tau = 1$: el reloj avanza Δt o hasta que se libere un operario, lo que ocurra primero

Cuadro 5: Transiciones por acción.

Así, ninguna transición dura más de Δt y todas acumulan costos de intervalos comparables. Cuando $\tau = 1$ ocurren los eventos estocásticos del ambiente: llegan órdenes (w, c y λ pueden subir), la holgura de las órdenes pendientes disminuye (u puede subir), operarios terminan su lote (o puede subir) y órdenes se completan o vencen. Si en el avance se alcanzan las 8 h, $s' = s_{\text{fin}}$.

4. Función de recompensa $R(s, a, s')$

La recompensa de cada tripla suma una parte inmediata, que depende del estado de salida y de la acción, y una parte de transición, que depende de lo que ocurrió entre s y s':

$$R(s, a, s') = R_{\text{acc}}(s, a) + R_{\text{tr}}(s, a, s').$$

La consolidación no se paga con un bono fijo por lote, sino por las *visitas ahorradas*: si un lote tiene ℓ líneas y visita v ubicaciones distintas, ahorra $n_{\text{ahorr}} = \ell - v$ visitas. Así, despachar muchos lotes pequeños no da más recompensa que uno grande, y esperar a que se acumulen SKU repetidos sí puede pagar.

4.1 Recompensa inmediata $R_{\text{acc}}(s, a)$

Cada viaje despachado (LOTE_z o $\mathsf{URGENTE}$) cuesta -1. Las reglas de $\mathsf{ESPERAR}$ se evalúan en orden; aplica la primera que se cumpla.

Acción	**Condición sobre** s	$R_{\text{acc}}(s, a)$
LOTE_z	Ninguna otra zona es crítica, o z también lo es	-1
	Otra zona es crítica ($\exists z' \neq z : u_{z'} = 3$) y z no ($u_z < 3$): descuido	$-1 - 10 = -11$
$\mathsf{URGENTE}$	$u_{\max} \geq 2$	-1
	$u_{\max} = 1$ (no hay urgencia: desperdicia consolidación)	$-1 - 4 = -5$
$\mathsf{ESPERAR}$	$s \in S_1$: $o = 0$ (no hay alternativa)	0
	$s \in S_2$: no hay trabajo pendiente	0
	$s \in S_3$: operario ocioso con una orden crítica	-10
	$s \in S_4$, $\lambda = 2$ y $c_z \leq 1$ $\forall z$ (esperar puede formar lotes más consolidados)	0
	$s \in S_4$ y $\lambda = 0$ (casi no llegan órdenes, esperar no sirve)	-3
	$s \in S_4$ en cualquier otro caso (operario ocioso)	-1

Cuadro 6: Recompensa inmediata por acción.

Ignorar una orden crítica cuesta -10 tanto si el operario espera como si se le asigna otra zona.

4.2 Recompensa de transición $R_{\text{tr}}(s, a, s')$

Sean n_{ahorr} las visitas ahorradas por el lote asignado (0 si $a = \mathsf{ESPERAR}$); n_{ok} y n_{venc} las órdenes completadas a tiempo y las que vencieron sin completarse durante $s \to s'$; A_{wip} el área de WIP del intervalo, es decir, la suma sobre el intervalo de las líneas pendientes sin asignar por los minutos que permanecen así ($\leq \Delta t$ minutos, porque el reloj nunca avanza más); y n_{pend} las órdenes sin despachar al llegar a s_{fin}. Como el estado agregado no guarda la identidad de cada orden, el simulador registra estos conteos en cada transición; para una tripla concreta su valor es conocido.

$$\begin{aligned} R_{\text{tr}}(s, a, s') = {} & 2\, n_{\text{ahorr}} + 3\, n_{\text{ok}} - 20\, n_{\text{venc}} - 0{,}05\, A_{\text{wip}} \\ & - \tau(s, a, s')\, \mathbf{1}[s' \neq s_{\text{fin}}] \sum_{z \in Z} \mathbf{1}[u'_z = 3] - 30\, n_{\text{pend}}\, \mathbf{1}[s' = s_{\text{fin}}]. \end{aligned}$$

Justificación de los valores.

Evento en la transición (s, a, s')	**Recompensa**
Cada visita ahorrada por el lote asignado $(\ell - v)$	$+2$
Cada orden completada antes de su deadline	$+3$
Cada orden que vence sin completarse (se cuenta una sola vez por orden)	-20
Cada línea pendiente sin asignar, por minuto transcurrido (costo de WIP)	$-0{,}05$
Cada zona con $u'_z = 3$ en s', solo si el reloj avanzó ($\tau = 1$) y $s' \neq s_{\text{fin}}$	-1
Llegada a $s' = s_{\text{fin}}$: cada orden pendiente sin despachar	-30
Acción inválida ($a \notin A(s)$, si no hay enmascaramiento); en este caso $s' = s$ y no aplica nada más	-50

Cuadro 7: Recompensas de transición.

- Vencer una orden (-20) cuesta más de lo que se gana consolidando sus líneas (una orden tiene a lo sumo 6 líneas: $\leq +12$), así que el agente no debería sacrificar un deadline por consolidar.
- El costo de WIP hace que esperar nunca sea gratis: con 20 líneas pendientes, esperar $\Delta t = 2$ min cuesta -2, lo mismo que una visita ahorrada. Esperar solo conviene si las órdenes que llegan comparten SKU con las pendientes, que es justamente el balance que el agente debe descubrir.
- Cobrar por visita ahorrada, y no por lote, evita que el agente gane recompensa fragmentando el trabajo en muchos lotes pequeños; el -1 por viaje refuerza lo mismo.

Descuento. Como el reloj avanza a lo sumo Δt por decisión pero algunas decisiones son inmediatas ($\tau = 0$), el descuento se aplica por tiempo transcurrido y no por decisión: $\gamma^{\Delta_{\min}/\Delta t}$ con $\gamma = 0{,}95$ por cada $\Delta t = 2$ min. Una decisión inmediata no se descuenta, de modo que asignar varios operarios en el mismo instante no aplaza artificialmente las recompensas futuras.

4.3 Triplas (s, a, s') de ejemplo

La tabla aplica la función completa a transiciones concretas que cubren todas las clases de estado y todas las acciones. Notación: $s = (w_A, w_B, w_C, w_D \mid c_A, c_B, c_C, c_D \mid u_A, u_B, u_C, u_D \mid o, \lambda)$. Para calcular el costo de WIP se indica cuántas líneas hay pendientes; las órdenes que llegan en el intervalo se suponen al final de este.

Las triplas T1 y T2 muestran el caso que motiva la aplicación: con una orden crítica en A y 5 órdenes que piden el mismo SKU en B, atender primero la urgencia cuesta -1, mientras que ir a B de inmediato daría $-1 - 10 + 8 = -3$ y arriesgaría el vencimiento de A. Luego el agente recoge el SKU repetido en una sola visita (T2, $+8$ por ahorro), en vez de ir 5 veces a la misma ubicación. T7 muestra el costo de ignorar una urgencia por perseguir consolidación.

#	**Estado de salida s y de llegada s'**	**Acción a**	**Cálculo**	$R(s,a,s')$
T1	$s = (1,2,0,0\|0,2,0,0\|3,1,0,0\|2,1)$ $s' = (0,2,0,0\|0,2,0,0\|0,1,0,0\|1,1)$	LOTE_A	A tiene 3 líneas críticas de 3 SKU distintos: viaje -1, sin visitas ahorradas; queda un operario libre y hay WIP en B, $\tau = 0$	-1
T2	$s = (0,2,0,0\|0,2,0,0\|0,1,0,0\|1,1)$ $s' = (0,0,1,0\|0,0,0,0\|0,0,1,0\|1,1)$	LOTE_B	B tiene 8 líneas: 5 órdenes piden el mismo SKU más 3 SKU distintos, 4 visitas: viaje -1, ahorro $4 \times 2 = +8$; en los 2 min termina el lote de A y se completa su orden $(+3)$; no quedan líneas sin asignar; llegan órdenes a C	$+10$
T3	$s = (2,1,0,0\|1,0,0,0\|1,1,0,0\|1,1)$ $s' = (2,0,0,0\|1,0,0,0\|1,0,0,0\|0,1)$	$\mathsf{URGENTE}$	$u_{\max} = 1$: $-1-4$; la orden tenía 2 líneas en A y 1 en B; quedan 6 líneas en A: WIP $6 \times 2 \times 0{,}05 = -0{,}6$	$-5{,}6$
T4	$s = (0,0,1,0\|0,0,0,0\|0,0,3,0\|1,1)$ $s' = (0,0,1,0\|0,0,0,0\|0,0,3,0\|1,1)$	$\mathsf{ESPERAR}$	$s \in S_3$: -10; la orden crítica de C (1 línea) vence: -20; C sigue crítica: -1; WIP $-0{,}1$	$-31{,}1$
T5	$s = (2,1,0,0\|1,1,0,0\|1,1,0,0\|1,2)$ $s' = (2,1,0,0\|2,1,0,0\|1,1,0,0\|1,2)$	$\mathsf{ESPERAR}$	$s \in S_4$, $\lambda = 2$, $c_z \leq 1$: 0; 11 líneas pendientes: WIP $-1{,}1$; llegan órdenes y c_A sube a 2	$-1{,}1$
T6	$s = (3,1,0,0\|1,0,0,0\|2,1,0,0\|0,1)$ $s' = (3,1,0,0\|1,0,0,0\|2,1,0,0\|1,1)$	$\mathsf{ESPERAR}$	$s \in S_1$: 0; se completa una orden: $+3$; 22 líneas pendientes: WIP $-2{,}2$	$+0{,}8$
T7	$s = (0,2,1,0\|0,2,0,0\|0,1,3,0\|1,1)$ $s' = (0,0,1,0\|0,0,0,0\|0,0,3,0\|0,1)$	LOTE_B	Lote de T2 $(-1+8)$; descuido (C es crítica): -10; vence la orden de C: -20; C sigue crítica: -1; WIP $-0{,}1$	$-24{,}1$
T8	$s = (1,0,0,0\|0,0,0,0\|3,0,0,0\|0,0)$ $s' = s_{\text{fin}}$	$\mathsf{ESPERAR}$	$s \in S_1$: 0; WIP $2 \times 2 \times 0{,}05 = -0{,}2$; termina el turno con 2 órdenes pendientes: $2 \times (-30)$	$-60{,}2$
T9	$s = (1,2,0,0\|0,2,0,0\|3,1,0,0\|2,1)$ $s' = s$ (sin cambio)	LOTE_C	$w_C = 0$: acción inválida	-50

Cuadro 8: Ejemplos de recompensa para triplas (s, a, s').